Olist 머신러닝 · 딥러닝 실습 ①

PART 1 ~ 5 데이터 이해와 분석

어떤 데이터인지 알고 · 연결하고 · 숫자로 패턴을 찾는다

전체 지도

다섯 파트가 하는 일

PART 1

데이터 소개

어떤 쇼핑몰의 어떤 데이터?

결과물

개념 이해

PART 2

데이터 준비

어디에 어떻게 받아 둘까?

결과물

Drive에 CSV 9개

PART 3

구조 이해

표끼리 어떻게 연결될까?

결과물

연결 구조(ERD)

PART 4

데이터 병합

8개 표를 하나로 합치면?

결과물

통합 데이터 119,143행

PART 5

EDA

숫자에서 어떤 패턴이 보일까?

결과물

인사이트 10가지

흐름 데이터 이해 → 준비 → 구조 파악 → 연결 → 패턴 찾기 → (PART 6~10 모델로)

어떤 데이터?

PART 1

브라질의 실제 쇼핑몰 데이터

브라질

실제 이커머스 플랫폼 Olist

2016~2018

약 2년치 주문

약 10만 건

주문 99,441건

CSV 9개

주문·고객·상품·판매자·리뷰 …

1 실무형 구조

실제 쇼핑몰처럼 여러 표로 나뉘어 있습니다.

2 다양한 AI 실습

추천 · 감성 분석 · 군집 · 이탈 예측을 한 데이터로 합니다.

3 연결이 핵심

표들을 ID로 연결해야 의미 있는 분석이 됩니다.

출처 : Kaggle · Brazilian E-Commerce Public Dataset by Olist

어떻게 준비?

PART 2

데이터는 한 번만 받아 Drive에 둔다

1

Drive 연결

Colab이 초기화돼도 파일이 남도록

셀 1

2

폴더 만들기

Drive 안 Olist/data 폴더 (base_path · 셀 3)

셀 2~3

3

Kaggle에서 받기

kagglehub로 임시 폴더 (path)에 받음

셀 4~5

4

Drive로 복사

CSV 9개를 base_path로 복사

셀 6

5

CSV 확인

목록 확인 + 고객 표 한 번 읽어 보기

셀 7~8

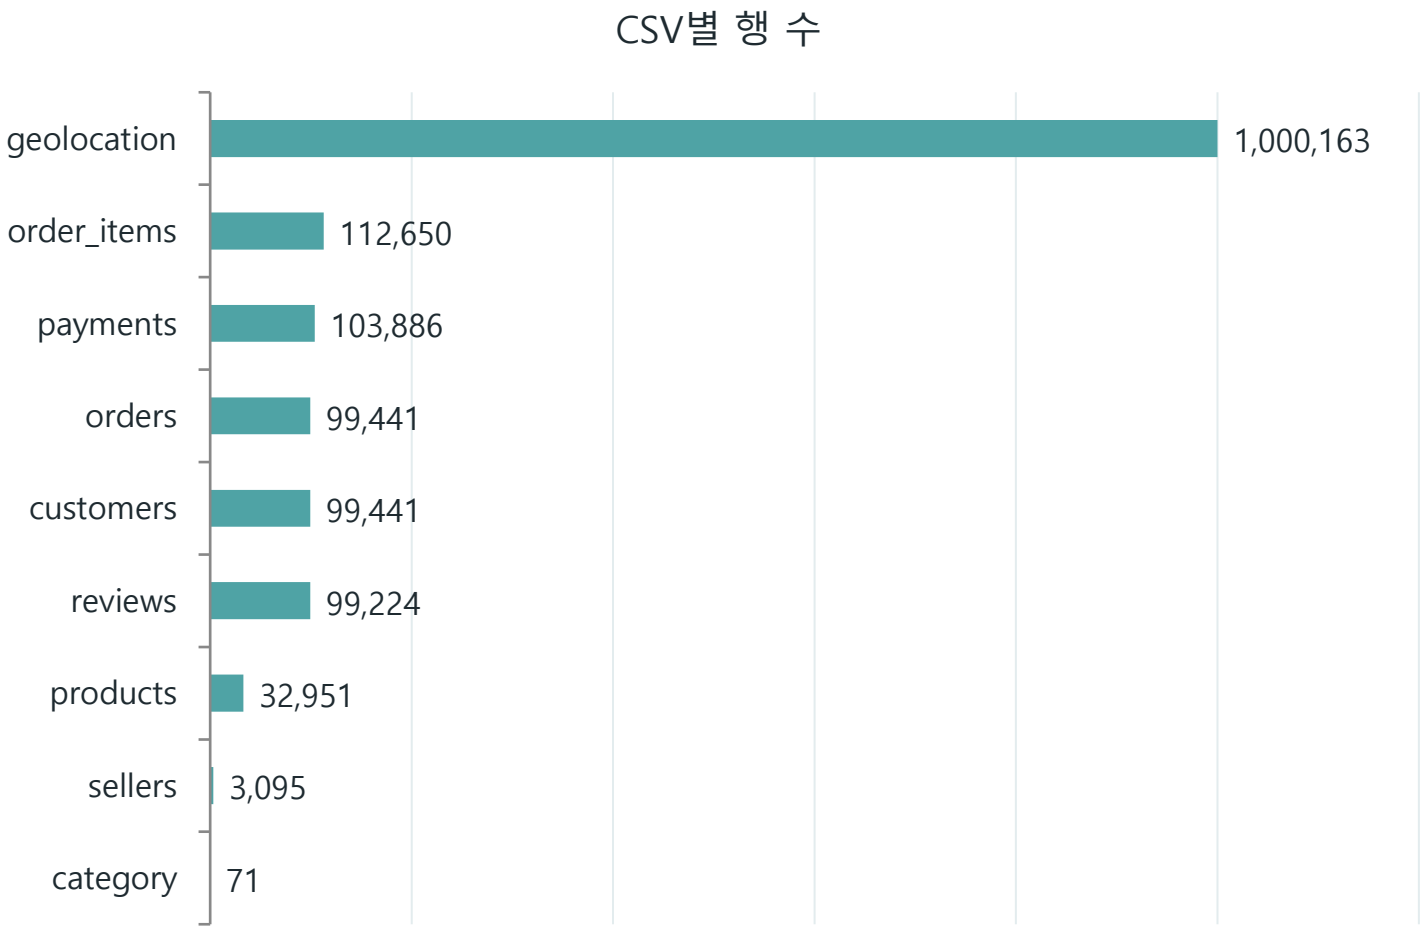
핵심 **모든 PART가 같은 경로(base_path)를 쓴다 → 경로 오류가 가장 흔한 실수**

✅ **정상 확인** 셀 7에서 "CSV 파일 개수: 9개"가 나오면 정상 (PART 4 이후에는 10개)

무엇이 들어 있나?

PART 2

9개 CSV, 크기는 제각각



가장 큰 표 : geolocation

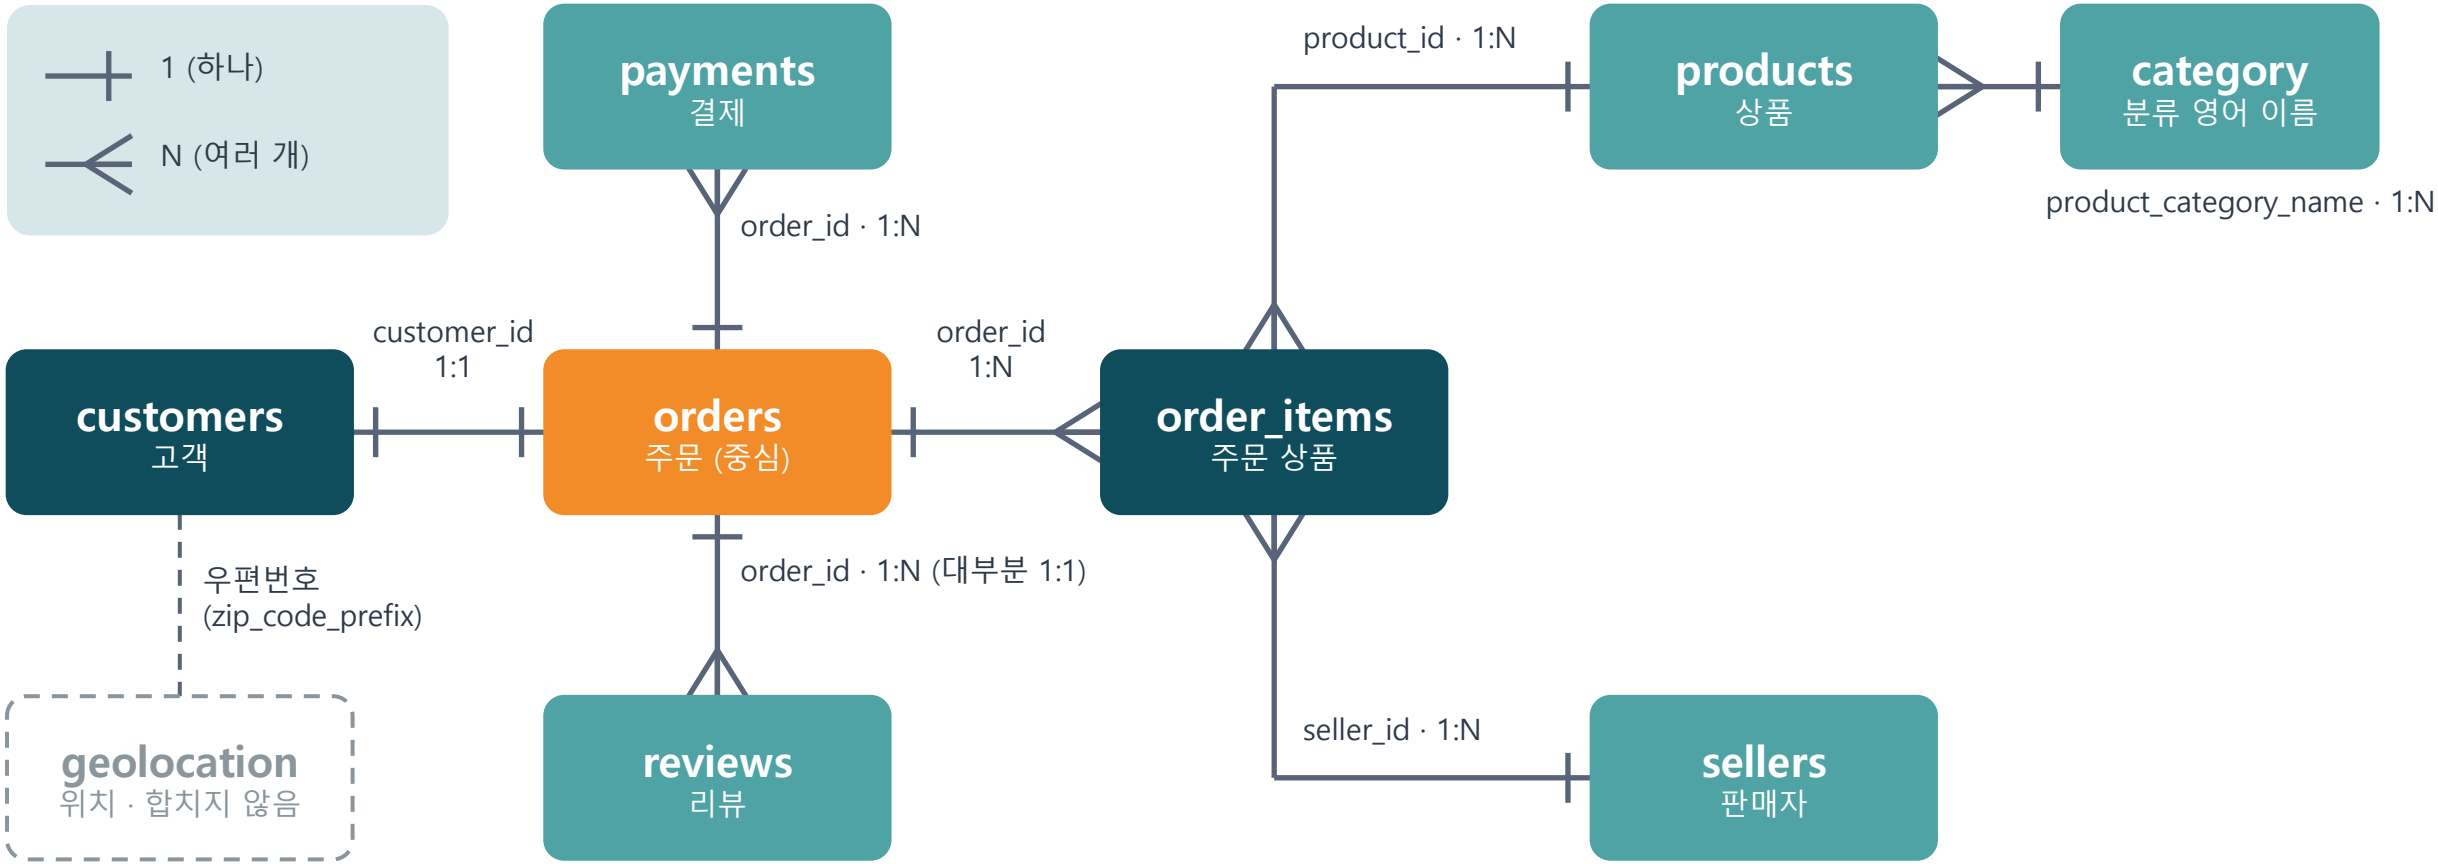
우편번호별 위치 정보. 100만 행이지만 이번 실습에서는 쓰지 않습니다.

주의 : 고객 번호가 2개

- customer_id : 주문마다 새로 발급
- customer_unique_id : 실제 한 사람

PART 3

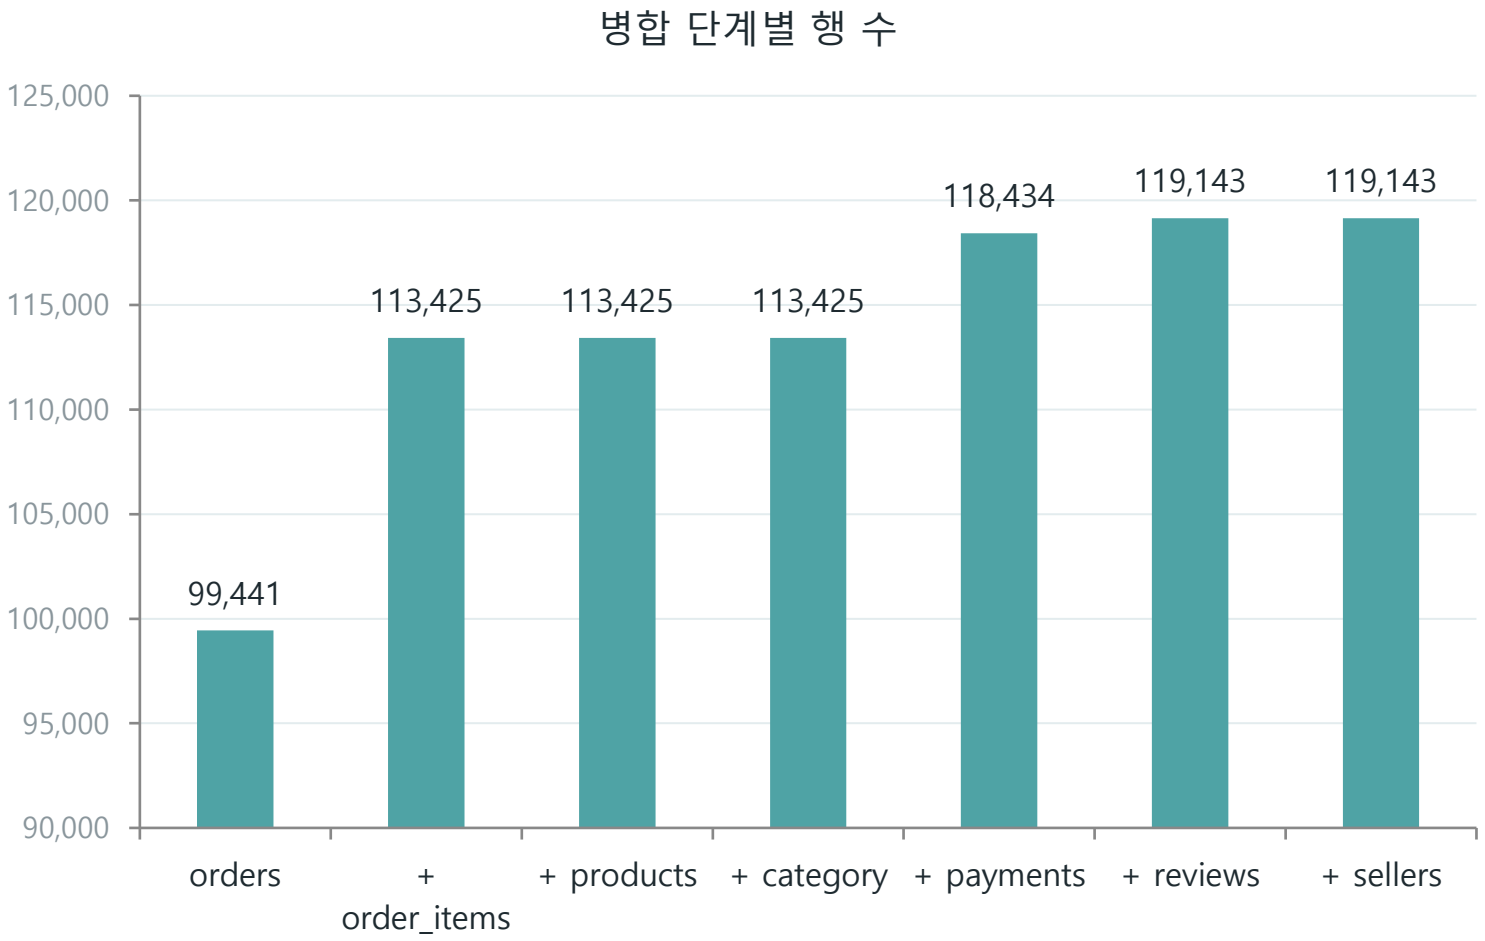
orders를 중심으로 ID로 연결된다



· 라벨은 1 쪽을 먼저 적는다 (1:N). · customers–orders가 1:1인 이유 : customer_id는 주문마다 새로 생긴다. 같은 사람은 customer_unique_id로 찾는다. · geolocation은 우편번호로 customers·sellers와 이어지지만 이번 실습에서는 합치지 않는다.

PART 4

합칠수록 행이 늘어난다 (오류 아님)



+13,984

상품 붙이기 : 상품이 여러 개인 주문

+5,009

결제 붙이기 : 나눠 결제한 주문

+709

리뷰 붙이기 : 리뷰가 2개 이상인 주문

왜 늘어나나?

PART 4

주문 1건이 여러 행으로 펼쳐진다

주문 A : 상품 2개 × 결제 2건

order_id	상품	결제
주문 A	상품 ①	결제 ①
주문 A	상품 ①	결제 ②
주문 A	상품 ②	결제 ①
주문 A	상품 ②	결제 ②

→ 같은 주문이 4행

! 그냥 더하면 중복 계산

통합 데이터의 결제 금액을 그대로 더하면 같은 결제가 여러 번 더해집니다. PART 5는 '무엇을 세는지'에 맞는 표로 집계합니다.

결과물

- olist_master_data.csv
- 119,143행 · 40열
- PART 5, PART 7-1~7-3에서 사용

먼저 정할 것 ①

PART 5

무엇을 세는지에 맞는 표로 센다

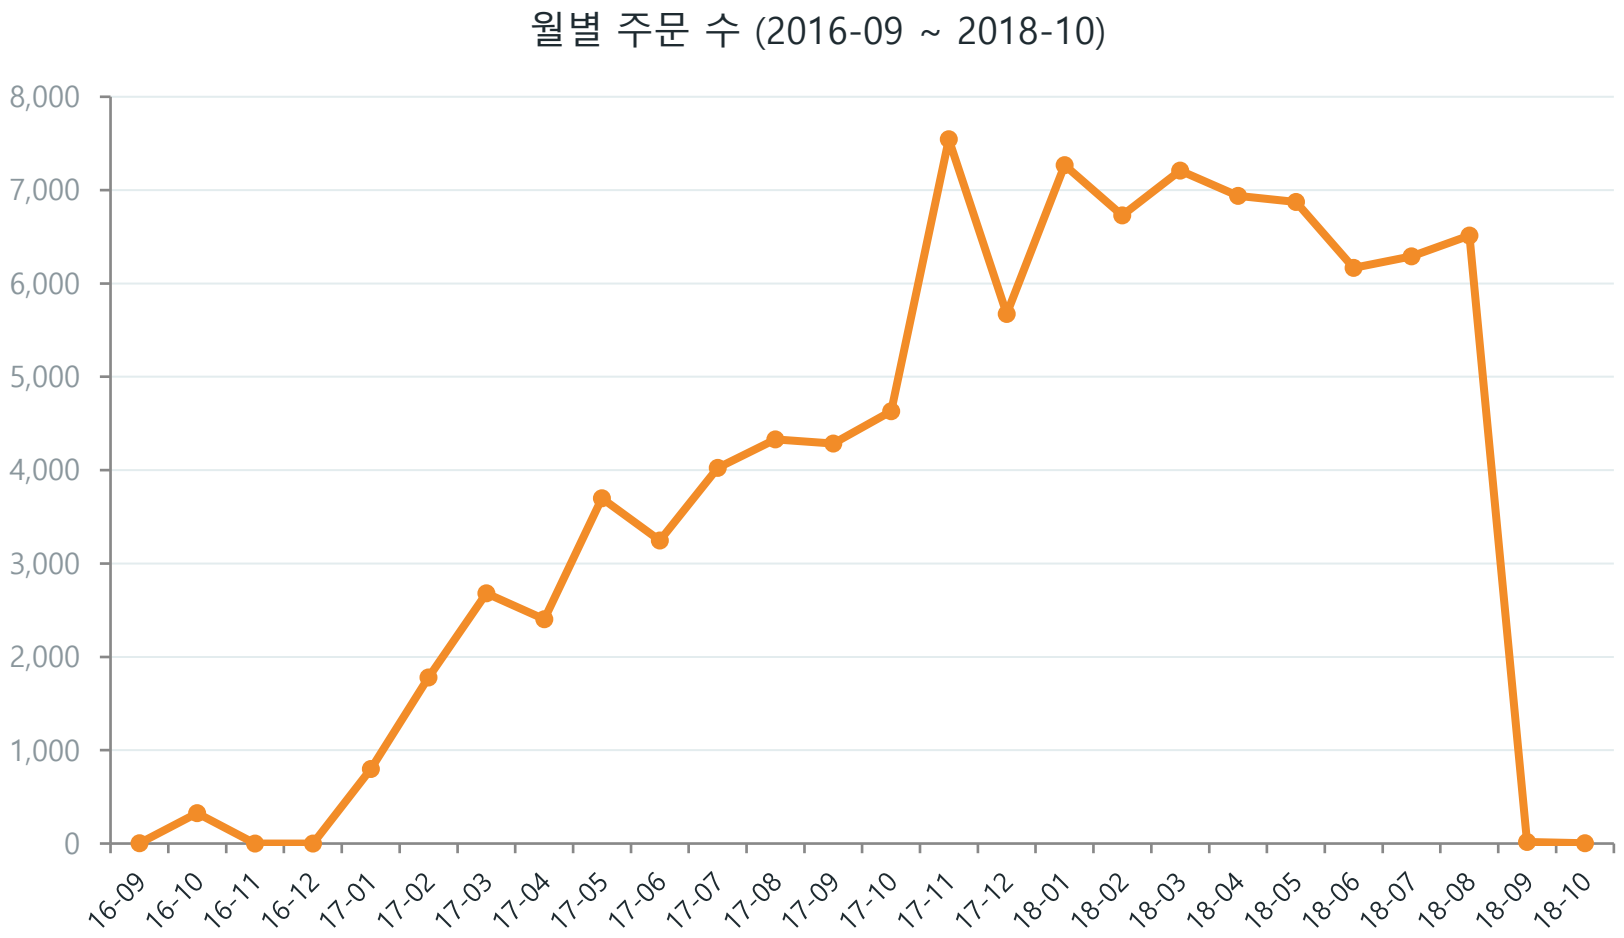
주문 수	orders	주문 1건 = 1행
판매 상품 수	items	판매된 상품 1개 = 1행
매출	pay	결제 1건 = 1행
리뷰 점수	orders	리뷰가 2개 이상이면 첫 번째만 사용

왜?

통합 데이터는 주문이 여러 행이라 그대로 세면 숫자가 부풀려집니다.

PART 5

앞뒤로 비어 있는 기간은 뺀다



그래프가 뚝 떨어진다?

2018-09는 16건, 10월은 4건.
실제 하락이 아니라 데이터 수집이 끝난 것

분석 기간

- 2017-01-05 ~ 2018-08-29
- 배송 완료 주문
- 96,203건 (base)

무엇을 찾았나?

PART 5

인사이트 10가지

1 **고객 대부분이 한 번 사고 떠난다**
1회 구매 97.0%

2 **고객은 남동부 3개 주에 몰려 있다**
SP·RJ·MG 66.6%

3 **신용카드 할부가 구매의 기본**
카드 75.5%, 그중 할부 66.8%

4 **'보통 주문'은 평균보다 훨씬 작다**
평균 R$160 vs 중앙값 R$105

5 **성장은 주문 수에서 왔다**
주문 2.40배, 객단가 +1.4%

6 **블랙프라이데이**
하루 1,147건 (평소 7.8배)

7 **평일 낮에 산다**
10~16시 45.2%

8 **많이 팔린 것 ≠ 돈 되는 것**
시계·선물 개수 7위 → 매출 2위

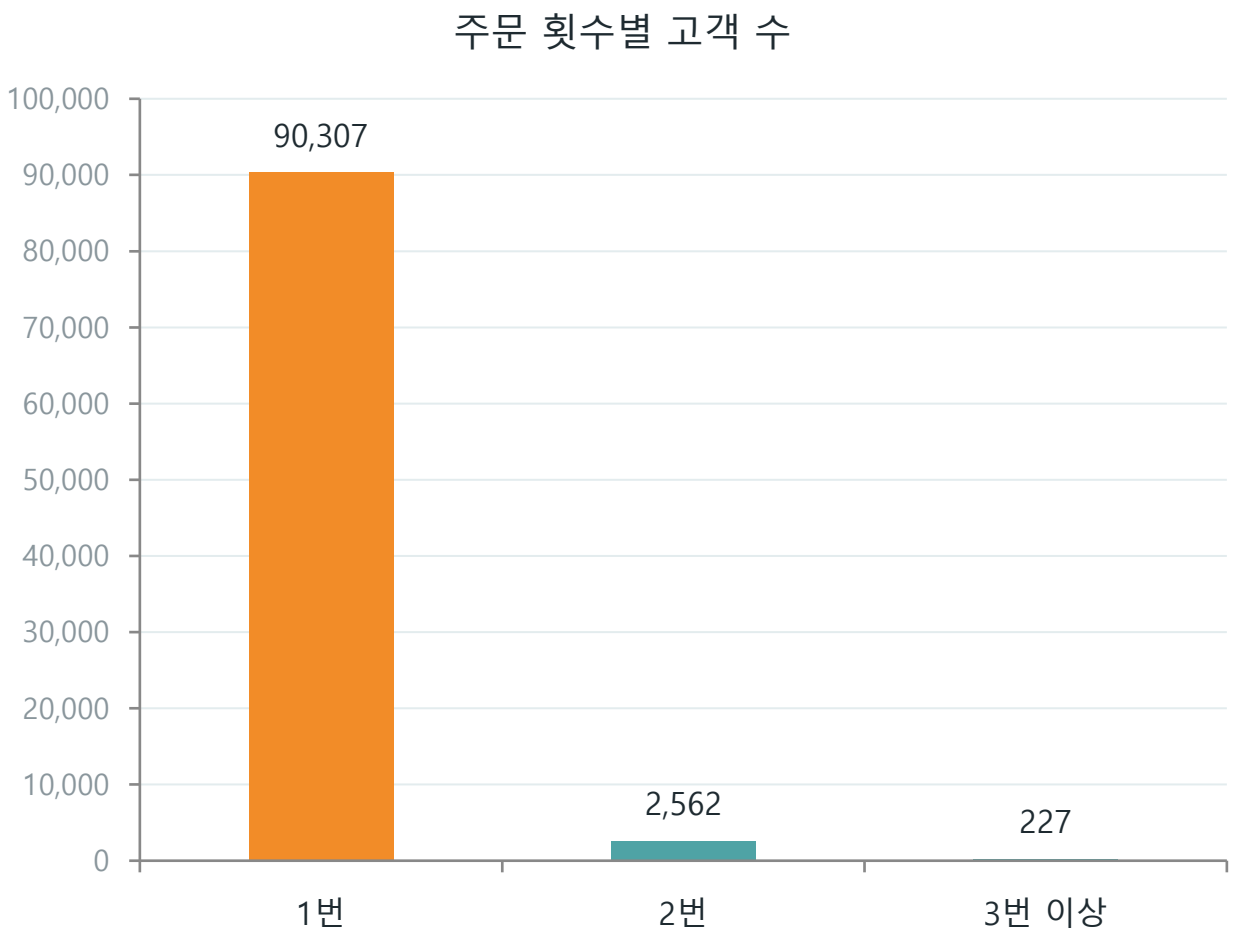
9 **배송이 늦으면 리뷰가 무너진다**
평균 리뷰 4.30 → 2.57

10 **성수기·먼 지역은 배송이 늦다**
SP 7.2일 vs 북부 24~26일

핵심 인사이트 ①

PART 5

고객의 97%는 한 번 사고 떠난다



97.0%

한 번만 구매한 고객 (93,096명 중)

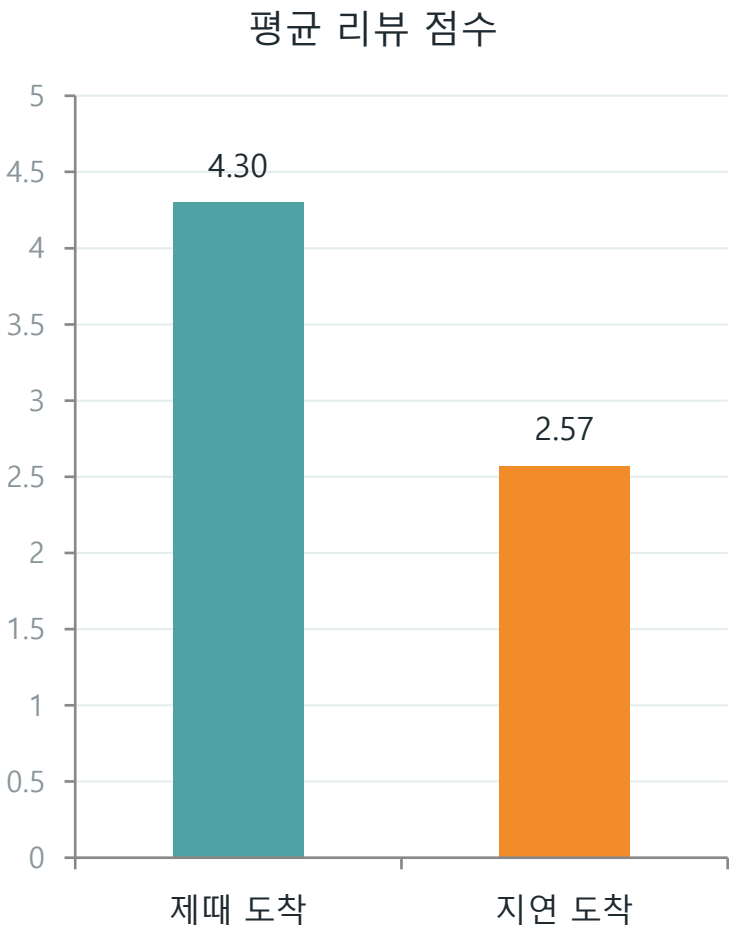
→ 그래서 PART 6 · 9에서

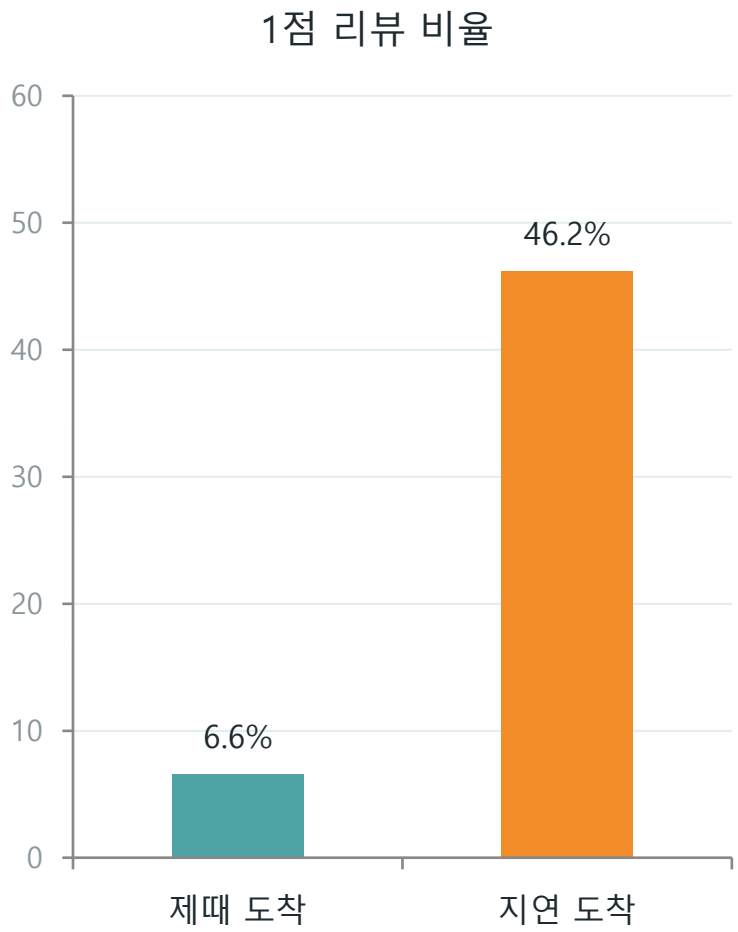
- "비슷한 고객이 산 상품" 추천 불가 → 상품 특징으로 추천 (PART 6)
- 고객은 거의 전부 '이탈' → 판매자 이탈 예측 (PART 9)

핵심 인사이트 ②

PART 5

배송이 늦으면 리뷰가 무너진다





8.1%

배송 완료 주문 중 지연 도착 비율

→ 그래서 PART 7 · 8에서

- 리뷰 글로 불만 자동 분류 (PART 7)
- 지연·저평점이 몰린 판매자 찾기 (PART 8)

핵심 인사이트 ③

PART 5

성장은 객단가가 아니라 주문 수에서 왔다

2.40배

주문 수 (2017 → 2018, 같은 1~8월)

+1.4%

객단가 (주문 1건당 금액)

무슨 뜻?

지금까지는 새 고객이 많이 들어와서 성장했습니다. 재구매도 3%뿐이라, 다음 성장은 한 번 살 때 더 많이 사게(객단가 ↑) 만드는 데서 찾아야 합니다.

→ 그래서 PART 6에서

상품 페이지에 '비슷한 상품'을 보여주는 추천으로 객단가를 높입니다.

다음으로

PART 5의 발견이 PART 6~10의 문제가 된다

인사이트 1 · 5 재구매 3%, 성장은 주문 수	→	**PART 6** 유사 상품 추천
인사이트 9 배송 지연 → 리뷰 급락	→	**PART 7** 리뷰 감성 분석
인사이트 9 · 10 지연·저평점 판매자	→	**PART 8** 판매자 유형
인사이트 1 고객 이탈 예측은 어려움 (재구매 3%)	→	**PART 9** 판매자 이탈 예측

PART 10 비즈니스 전략에서 모든 결과를 실행 계획으로 묶습니다