Olist 머신러닝 · 딥러닝 실습 ②

PART 6 ~ 10 머신러닝과 전략

무엇을 하기 위해 · 어떤 데이터로 · 어떤 알고리즘으로 · 어떻게 하는가

전체 지도

다섯 파트가 하는 일

PART 6

유사 상품 추천

같은 카테고리면 비슷한 상품일까?

데이터
상품 2,498개

방법
규칙 vs KNN

PART 7

리뷰 감성 분석

글만 보고 불만을 알 수 있을까?

데이터
리뷰 37,139건

방법
TF-IDF · 딥러닝 · BERT

PART 8

판매자 유형

어떤 판매자들이 있을까?

데이터
판매자 2,502명

방법
K-Means

PART 9

판매자 이탈

누가 판매를 멈출까?

데이터
판매자 1,567명

방법
규칙 vs 로지스틱

PART 10

비즈니스 전략

내일 무엇을 할 수 있을까?

데이터
저장한 모델 4개

방법
최신 데이터에 적용

공통 흐름 PART 5의 문제 → 데이터 고르기 → 단순한 방법부터 → 머신러닝과 비교 → 모델 저장 → (STEP2 배포)

각 파트는 무엇을 보고(X) 무엇을 맞히나(y)

	X (모델이 보는 것)	y (맞혀야 할 정답)	
PART 6	상품의 가격·무게·크기·사진 수·평점	없음 → 비슷한 상품만 찾음	정답 없음
PART 7-1 · 7-2	리뷰 글 (숫자로 바꿈)	**긍정이냐 부정이냐 (별점으로 만듦)**	정답 있음
PART 7-3	리뷰 글	학습 안 함 → 정답과 비교만	학습 안 함
PART 8	판매자의 주문 수·판매액·최근 판매 등 5개	없음 → 비슷한 판매자끼리 묶음	정답 없음
PART 9	판매자의 과거 판매 기록 (기준일 이전)	**앞으로 3개월 안에 판매를 멈출까 (기준일 이후)**	정답 있음
PART 10	최신 판매자·리뷰·상품 데이터	학습 안 함 → 저장한 모델로 예측만	학습 안 함

정답 있음 (7 · 9) 정답을 보고 배운다

정답 없음 (6 · 8) 비슷한 것끼리 찾거나 묶는다

학습 안 함 (7-3 · 10) 이미 있는 모델을 쓴다

출발점

PART 5에서 발견한 것이 문제를 정한다

97%

고객이 한 번만 구매

→ 그래서

고객 기반 추천 X → 상품 추천 (6)
고객 이탈 X → 판매자 이탈 (9)

4.30 → 2.57

배송이 늦으면 리뷰 급락

→ 그래서

리뷰로 불만 찾기 (7)
지연 판매자 찾기 (8)

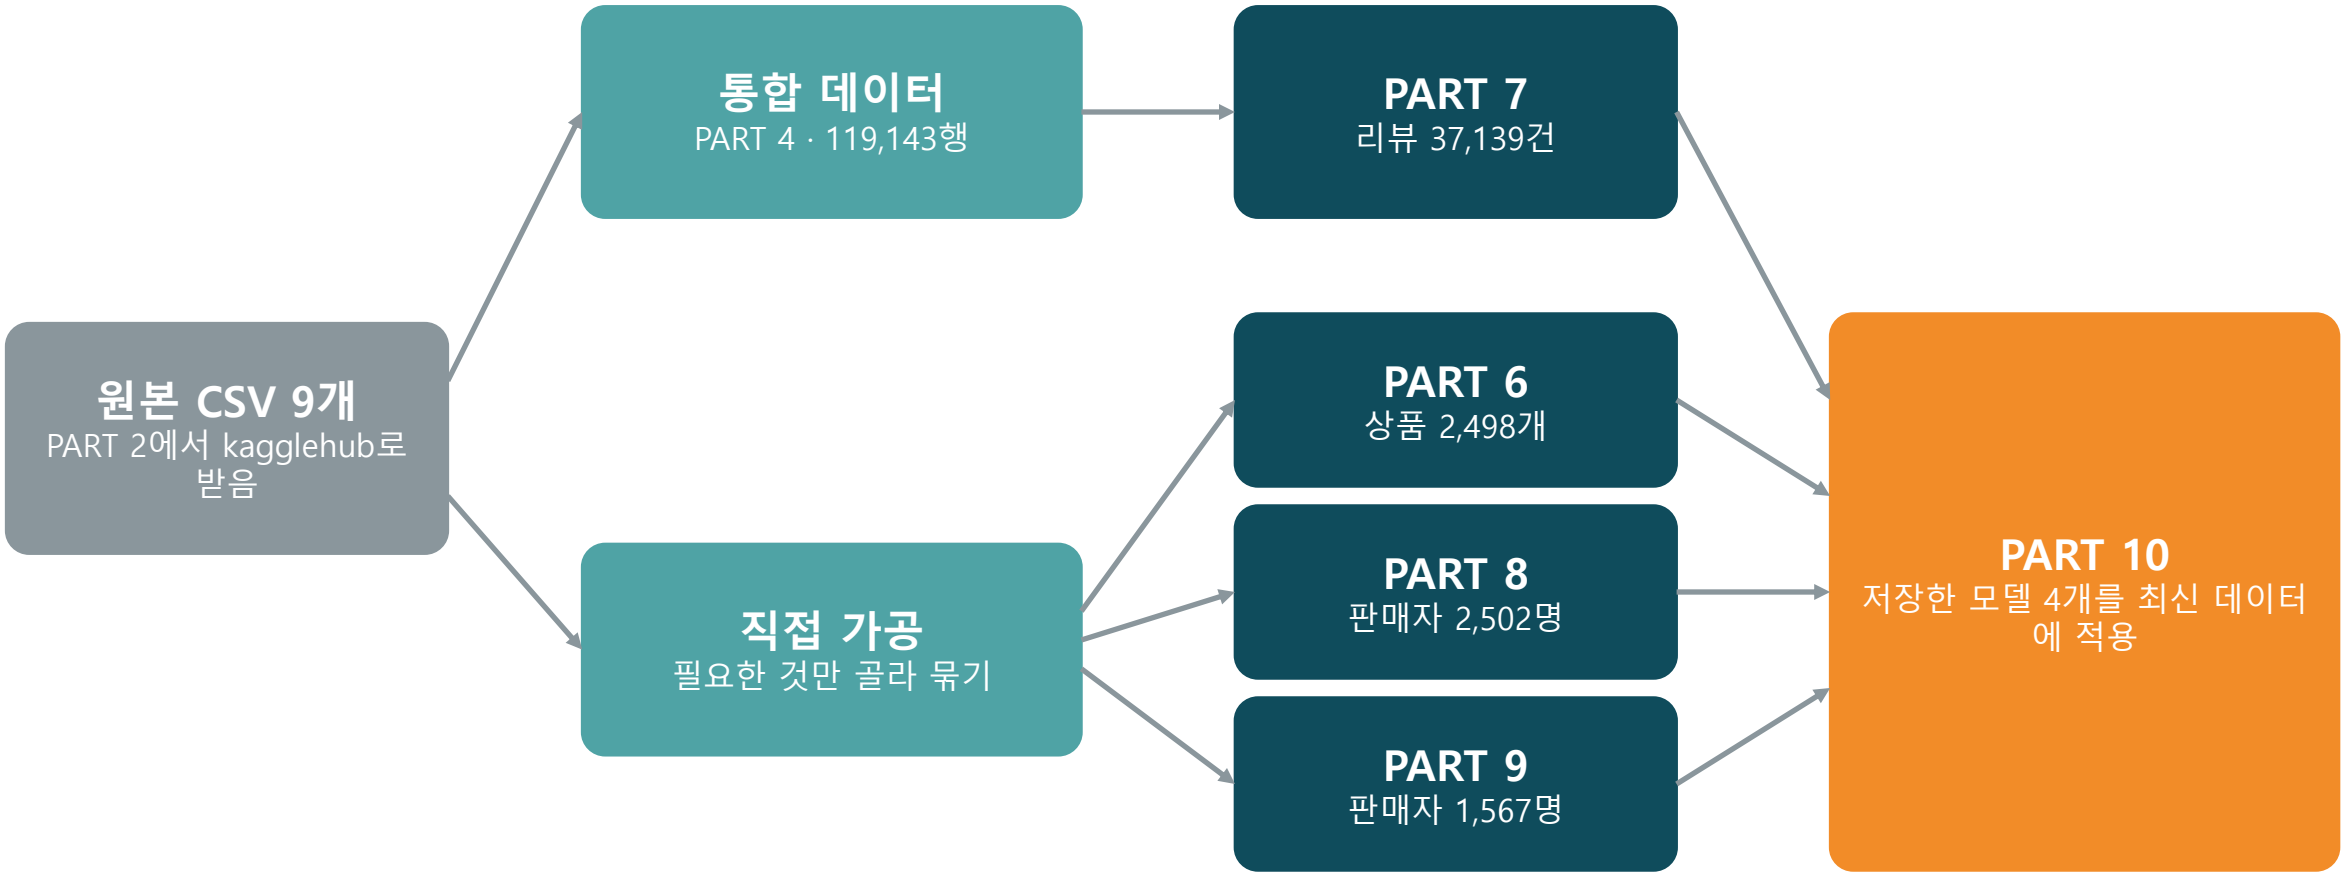
2.40배

성장은 주문 수에서

→ 그래서

객단가를 높일 추천 (6)

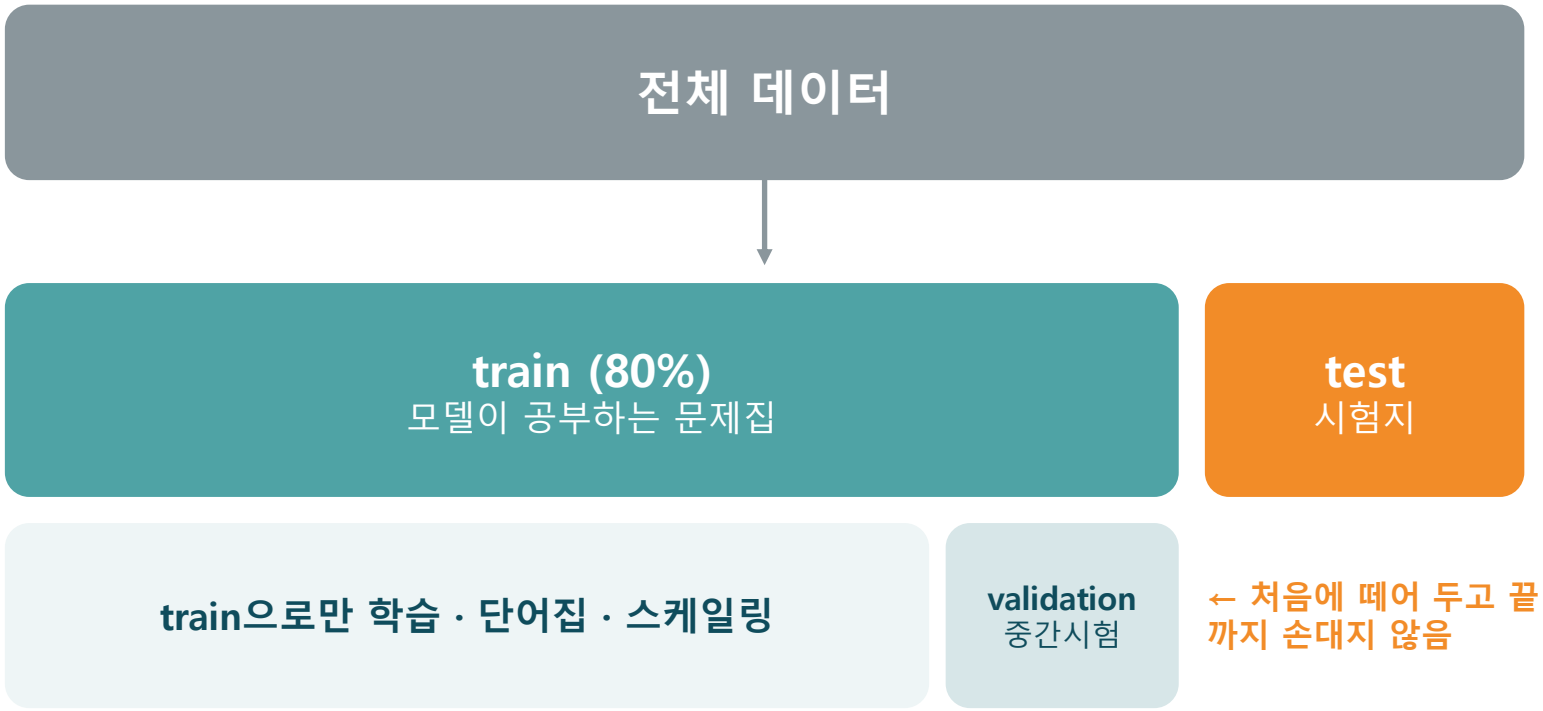
파트마다 쓰는 데이터



PART 6·8·9·10 공통 : 2017-01 ~ 2018-08 · 취소·구매 불가 주문 제외 · 실제 데이터만 고르기 (PART 7은 통합 데이터의 리뷰)
출처 : Kaggle · Brazilian E-Commerce Public Dataset by Olist

공통 개념

공부한 문제가 시험에 나오면 안 된다



데이터 누수 = 예측할 때는 모를 정보(시험지, 미래)가 학습에 섞이는 것 → 점수가 실제보다 좋게 나옴

파트마다 이렇게 지킨다

- PART 7 : 같은 리뷰 중복부터 제거 → test·validation 먼저 분리
- PART 8·9 : 기준일 2018-06-01로 과거(특징)와 미래(정답)를 나눔 · PART 9의 train/test는 판매자를 무작위로 나눔
- PART 9 : 규칙의 기준(30일)도 train으로만 고르기

개념 ② 평가 지표 (PART 7 · 9)

공통 개념

정확도만 보면 속는다

PART 9 시험지 314명 · 로지스틱 회귀

	예측 : 유지	예측 : 이탈
실제 유지	164 맞힘	74 헛경보
실제 이탈	19 놓침	57 찾아냄

재현율 = 57 ÷ (57 + 19) = 0.75

실제 이탈 판매자 중 몇 명을 찾았나 → 놓치면 안 될 때 중요

정밀도 = 57 ÷ (57 + 74) = 0.435

이탈이라고 한 판매자 중 진짜는 몇 명? → 헛경보가 아까울 때 중요

F1 = 두 값의 균형 점수

재현율과 정밀도가 둘 다 높아야 높게 나옴 (여기서는 0.55)

이 모델의 정확도는 0.70 · 전부 '유지'로 찍으면 0.76

공통 개념

반반으로 만들지 않아도 된다

PART 7 리뷰 (긍정 71% : 부정 29%) · 같은 시험지 7,428건으로 비교

방법	학습 데이터	부정 재현율	부정 정밀도	부정 F1
① 그대로 (보정 없음)	29,711건	0.880	0.867	0.874
② class_weight (노트북 방식)	**29,711건**	**0.947**	**0.804**	**0.869**
③ 긍정을 버려 반반	17,214건	0.947	0.788	0.861
④ 부정을 복사해 반반	42,208건	0.941	0.812	0.872

②·③·④ 모두 부정 재현율이 약 0.94~0.95로 오름 → 하는 일이 같다

그래서 class_weight

- 데이터를 버리지도 복사하지도 않고 같은 효과
- ③은 데이터 42% 손실
- ④는 같은 문장 반복 → 과적합 위험
- 시험지는 실제 비율 그대로

① 무엇을 하기 위해?

PART 6

이 상품과 비슷한 상품 5개를 추천한다

같은 카테고리면 비슷한 상품일까?

상품 상세 페이지에 "비슷한 상품"을 보여 줘서 한 번에 더 많이 사도록(객단가 ↑) 만드는 것이 목표입니다.

1 왜 상품 기반 추천?

재구매 고객이 3%뿐이라 "비슷한 고객이 산 상품"(협업 필터링)은 배울 데이터가 없습니다. 상품 자체의 특징으로 추천합니다.

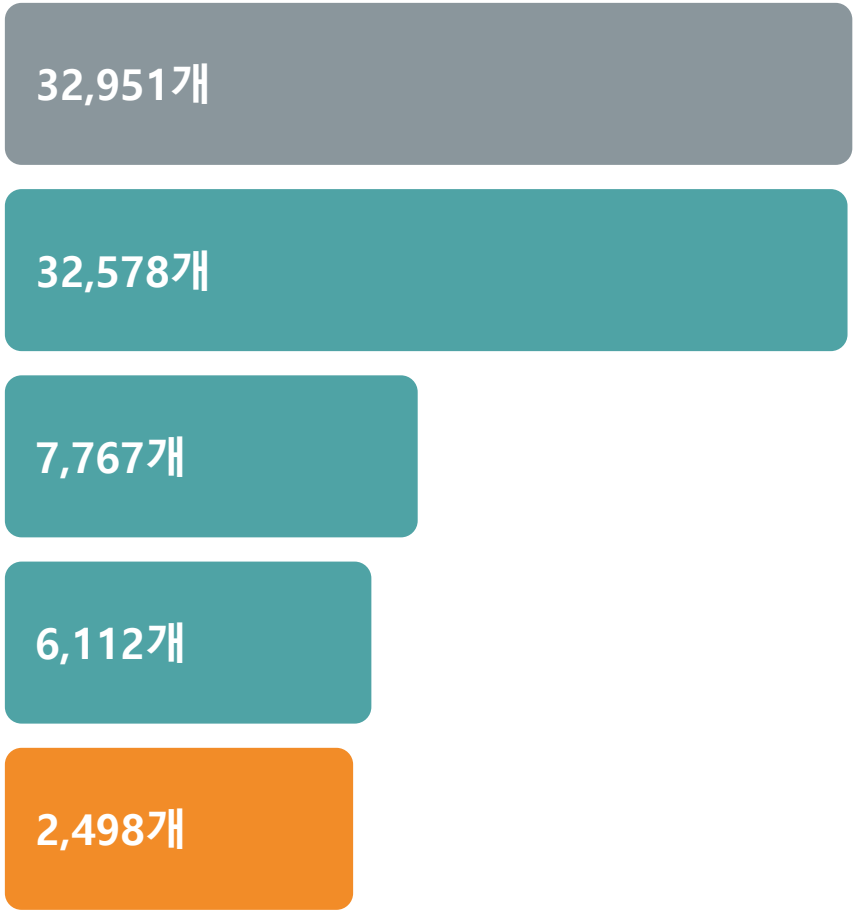
2 무엇과 비교?

사람이 정한 규칙(랜덤, 가격 조건)과 머신러닝(KNN)을 같은 기준으로 비교합니다.

② 어떤 데이터로?

PART 6

상품 32,951개에서 2,498개를 골랐다



원본 상품 테이블

기간 안에 유효 주문으로 팔린 상품

주문 3건 이상 + 무게·크기 정보 있음 (59%는 딱 1번 팔림)

상품이 많은 상위 15개 카테고리 (후보가 충분하도록)

카테고리 비율대로 뽑기 → 실습하기 좋은 크기

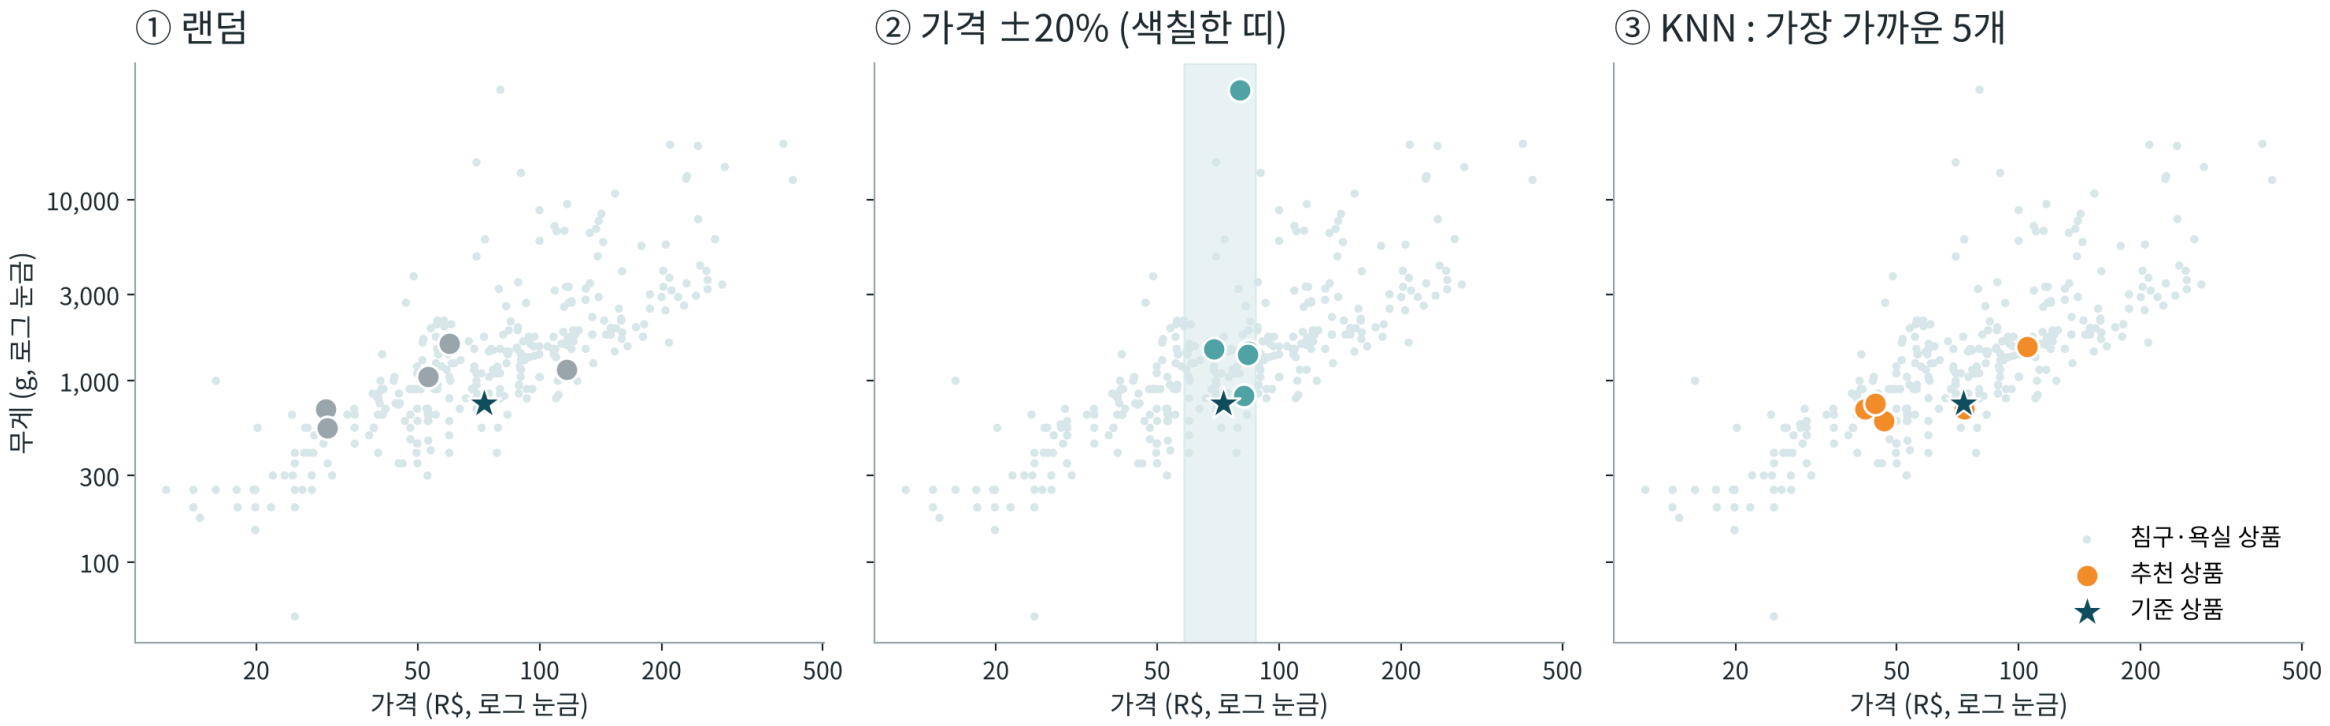
상품 1개 = 1줄

- 가격 (평균 판매가)
- 무게
- 가로 · 세로 · 높이
- 사진 수
- 평균 리뷰 점수
- 카테고리 (필터용)

③ 어떤 알고리즘으로?

PART 6

규칙 2가지와 KNN을 비교한다



침구·욕실 카테고리 안의 상품들 · ★ 기준 상품, 큰 점 = 추천된 5개 (가로 가격, 세로 무게)

① 랜덤 : 멀리 흩어짐

② 가격만 맞고 무게 40kg도 나옴

③ KNN : 기준 상품 주변에 모임

④ 어떻게?

PART 6

노트북은 이 순서로 진행된다

1

데이터 준비

유효 주문 · 3건 이상 · 상위 15개

셀 3~7

2

퍼짐 확인

같은 카테고리도 가격이 몇 배 차이

셀 8

3

랜덤 추천

같은 카테고리에서 5개

셀 9

4

가격 조건

가격 ±20% 안에서 5개

셀 10

5

KNN 추천

로그 → 스케일링 → 카테고리별 KNN

셀 11~12

6

비교 → 저장

2,498개 전체로 차이 비교

셀 13~16

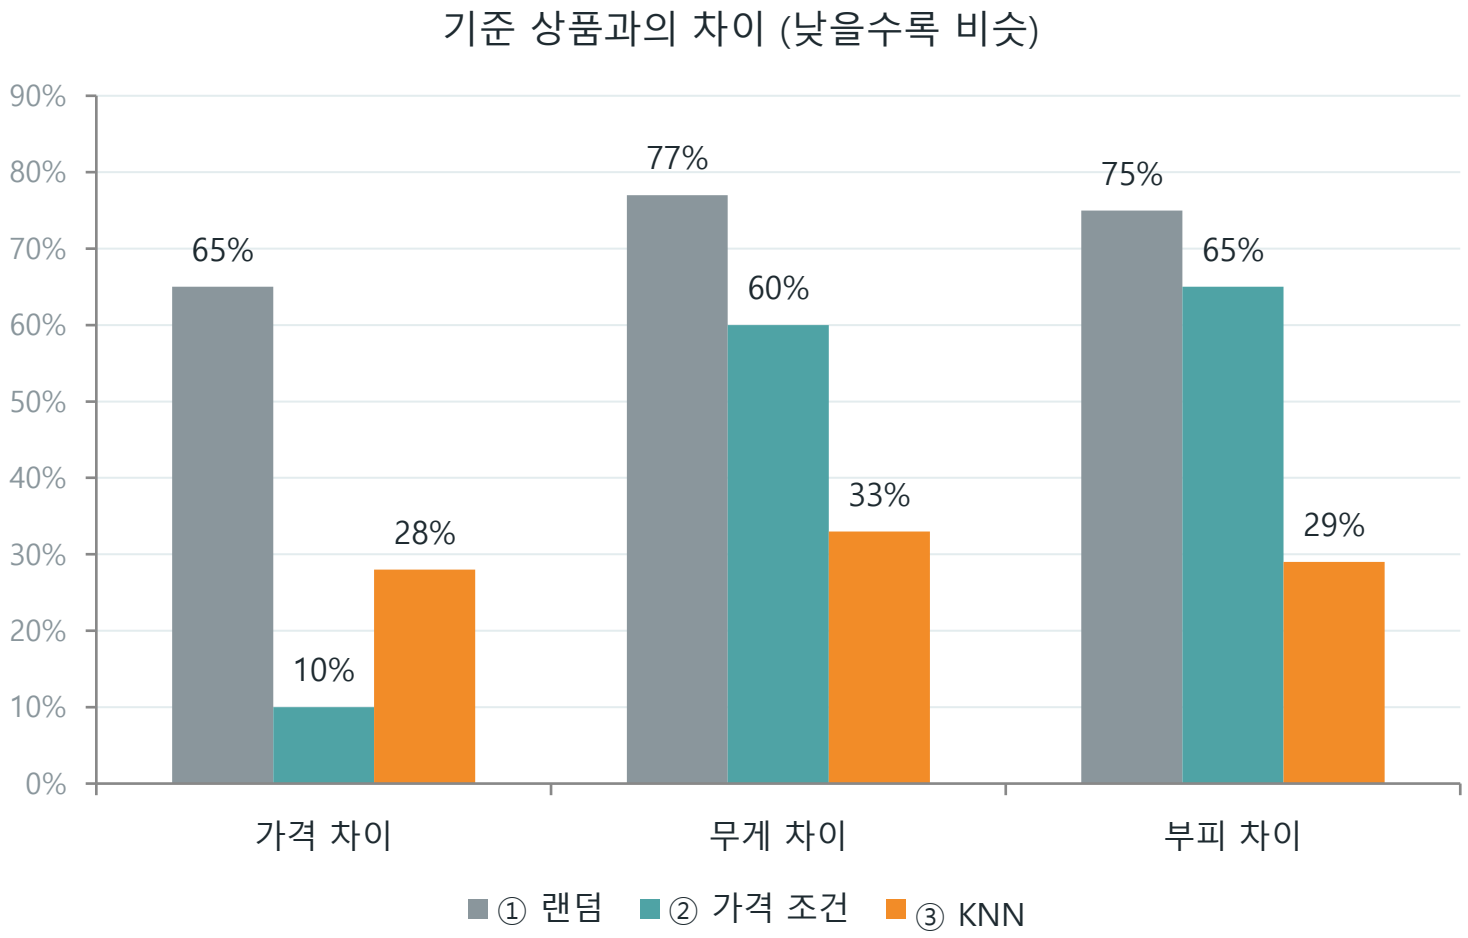
핵심 단순한 규칙부터 → 부족한 점 확인 → KNN으로 개선

✅ **정상 확인** 셀 7에서 "실습 데이터 : 2,498개 상품 / 15개 카테고리"가 나오면 정상

⑤ 무엇을 알았나?

PART 6

KNN이 모든 특징을 고르게 맞춘다



72% → 30%

랜덤 대비 KNN의 평균 차이

6%

가격 조건만 붙여도 후보 5개를 못 채운 상품

가격만 중요하면 규칙으로 충분, 여러 특징이 함께 비슷해야 하면 KNN

part6_recommend.pkl 약 160KB

① 무엇을 하기 위해?

PART 7

리뷰 글로 긍정·부정을 자동 분류한다

별점 없이 글만 보고 불만을 알 수 있을까?

리뷰가 수만 개라 사람이 다 읽을 수 없습니다. 부정 리뷰를 자동으로 골라 CS팀에 넘기는 것이 목표입니다.

1 배송이 늦으면 리뷰가 무너진다

지연되면 평균 리뷰가 4.30 → 2.57. 불만 리뷰를 빨리 찾아야 대응할 수 있습니다.

2 세 가지 방법, 같은 시험지

7-1 머신러닝, 7-2 딥러닝, 7-3 사전학습 BERT를 똑같은 test 리뷰로 비교합니다.

② 어떤 데이터로?

PART 7

글이 있는 리뷰 37,139건을 쓴다

119,143행

PART 4 통합 데이터 (같은 리뷰가 여러 행에 반복)

98,411건

review_id로 중복 제거 → 같은 리뷰가 시험지에 섞이지 않게

40,668건

글이 있는 리뷰만 (글이 없으면 배울 게 없음)

37,139건

애매한 3점 제외 → 4~5점 긍정, 1~2점 부정

정답(라벨)

- 긍정 26,380건 (71%)
- 부정 10,759건 (29%)

나누기

- train 29,711 / test 7,428
- 7-2 : train에서 검증용 5,943
- 7-3 : test 중 500건

③ 어떤 알고리즘으로?

PART 7

글을 숫자로 바꾸는 방법이 다르다

7-1 TF-IDF + 로지스틱 회귀

단어마다 '이 리뷰다운 정도' 점수 (예시)

	produto	muito	bom	não
리뷰1	0.41	0.58	0.70	0
리뷰2	0.33	0	0	0.56

- 단어 순서는 안 봄
- 단어별 가중치 → 판단 근거를 볼 수 있음
- 가장 가볍고 빠름

7-2 Embedding · Bi-LSTM

"Não veio com tudo" → 단어 번호

8	29	15	35
não	veio	com	tudo

- 번호 → 의미 벡터 (Embedding)
- Bi-LSTM은 단어 순서까지 읽음
- 직접 학습 (EarlyStopping)

7-3 사전학습 BERT

학습 없이 바로 사용

이미 학습된 거대 모델
→ 긍정 / 중립 / 부정

- 여러 언어 지원
- 우리 데이터로 학습하지 않음
- 용량 약 540MB

④ 어떻게?

PART 7

세 노트북은 이 순서로 진행된다

1	2	3	4	5	6
리뷰 준비	**시험지 분리**	**7-1 머신러닝**	**7-2 딥러닝**	**기준선 비교**	**7-3 BERT 비교**
중복 제거 · 글 없는 리뷰 · 3점 제외	test 20% 먼저 (모든 노트북 동일)	TF-IDF → 로지스틱 → 단어 해석	Tokenizer → Embedding · Bi-LSTM	전부 긍정 · 7-1 · 7-2 같은 test	같은 test 500건으로 세 모델
7-1 셀 3~4	7-1 셀 5	7-1 셀 6~12	7-2 셀 6~13-1	7-2 셀 13-2	7-3 셀 5~11

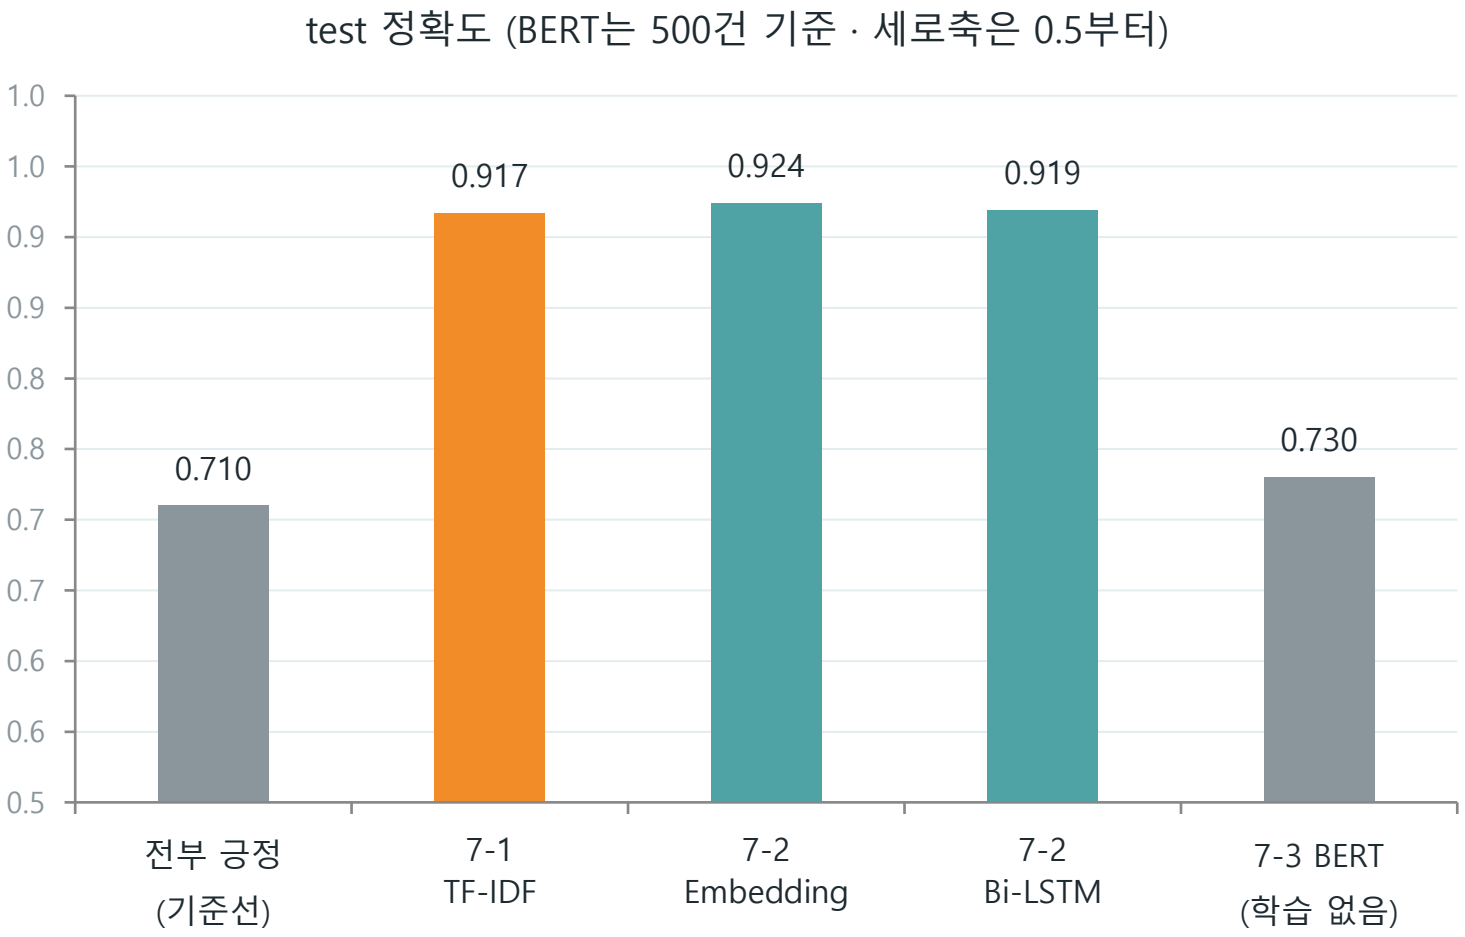
핵심 **7-1 → 7-2 → 7-3 순서로 실행 (앞에서 저장한 모델을 뒤에서 불러옴)**

✅ **정상 확인** 7-1 셀 4 "분석할 리뷰 수: 37,139" · 셀 8 "로지스틱 회귀 정확도 0.917"

⑤ 무엇을 알았나?

PART 7

딥러닝도 머신러닝을 크게 이기지 못했다



≈ 0.92

머신러닝 · 딥러닝 2종 모두 거의 같음

리뷰가 짧고 핵심 단어로 판단되는 문제라 단어 순서를 읽어도 얻을 게 적음

부정 단어 : 배송 지연 · 오배송 · 파손

part7_1_sentiment_ml.pkl 약 180KB

배포는 7-1 모델 · 7-2는 비교용 · BERT는 저장 안 함

① 무엇을 하기 위해?

PART 8

비슷한 판매자끼리 묶어 유형을 만든다

Olist에는 어떤 유형의 판매자들이 있을까?

판매자를 몇 가지 유형으로 나눠 유형마다 다른 관리 정책(혜택, 경고, 지원)을 세우는 것이 목표입니다.

1 지연과 저평점은 어디서?

지연과 낮은 평점이 몰린 판매자 그룹이 있는지, 지연이 판매자 출고 단계와 택배 단계 중 어디서 생기는지 확인합니다.

2 비지도 학습

정답(라벨) 없이 비슷한 것끼리 묶습니다. 묶은 뒤 이름을 붙이는 것은 사람의 몫입니다.

② 어떤 데이터로?

PART 8

판매자 1명을 1줄로 요약한다

주문 상품 11만 행

원본 주문 상품 테이블 (판매자가 여러 번 등장)

판매자 3,095명

원본 판매자 테이블

판매자 2,502명

2017-01 ~ 2018-05-31에 유효 주문
→ 1명 = 1줄로 묶기

왜 2018-05-31까지?

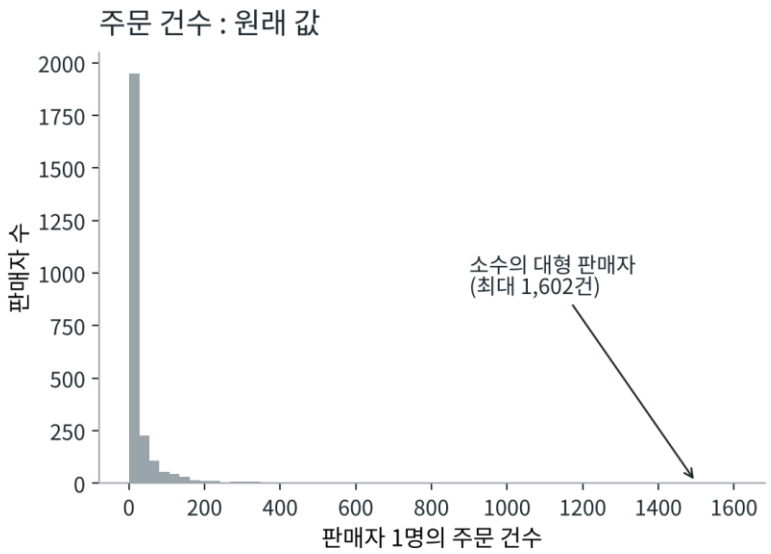
PART 9가 6~8월을 예측하므로 미래 정보가 섞이지 않게 기준일을 맞춤 (데이터 누수 방지)

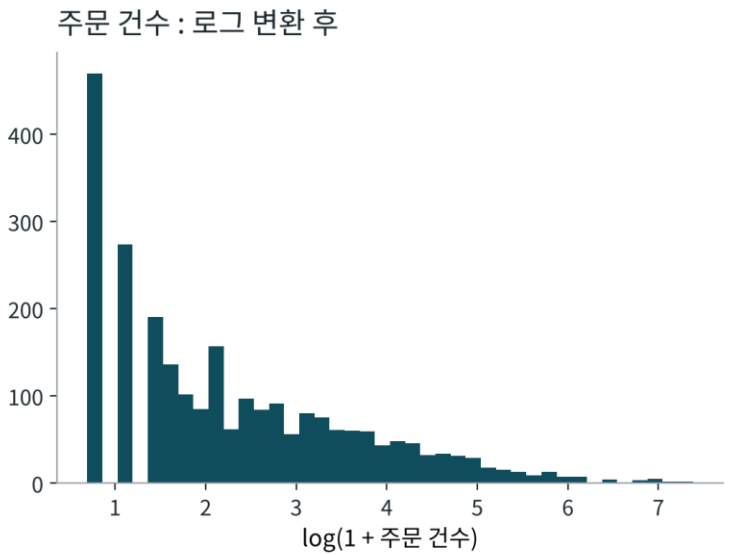
군집에 쓰는 특징 5개

- F : 주문 건수
- M : 판매액
- R : 마지막 판매 후 일수
- 활동 기간
- 평균 리뷰 점수

PART 8

로그 변환 후 K-Means로 묶는다





로그 변환 안 하면?

대형 판매자 22명이 군집 하나를 통째로 차지

로그 변환 후

947 · 876 · 461 · 218명으로 고르게 나뉨

K-Means는 3단계 반복

① 중심점 k개를 놓는다
② 판매자마다 가장 가까운 중심에 배정
③ 중심을 무리의 가운데로 옮긴다
→ 더 안 움직일 때까지 ②③ 반복

k는 사람이 정한다 → 다음 장

④ 어떻게?

PART 8

엘보우로 좁히고 실루엣으로 정한다

1 **판매자 프로필**

기준일까지 1명 = 1줄

셀 3~6

2 **로그 · 스케일링**

전후 군집 크기 비교

셀 7~8

3 **k 정하기**

k = 2~8 엘보우 + 실루엣

셀 9

4 **K-Means → 이름**

k = 4, 규칙으로 이름

셀 10~12

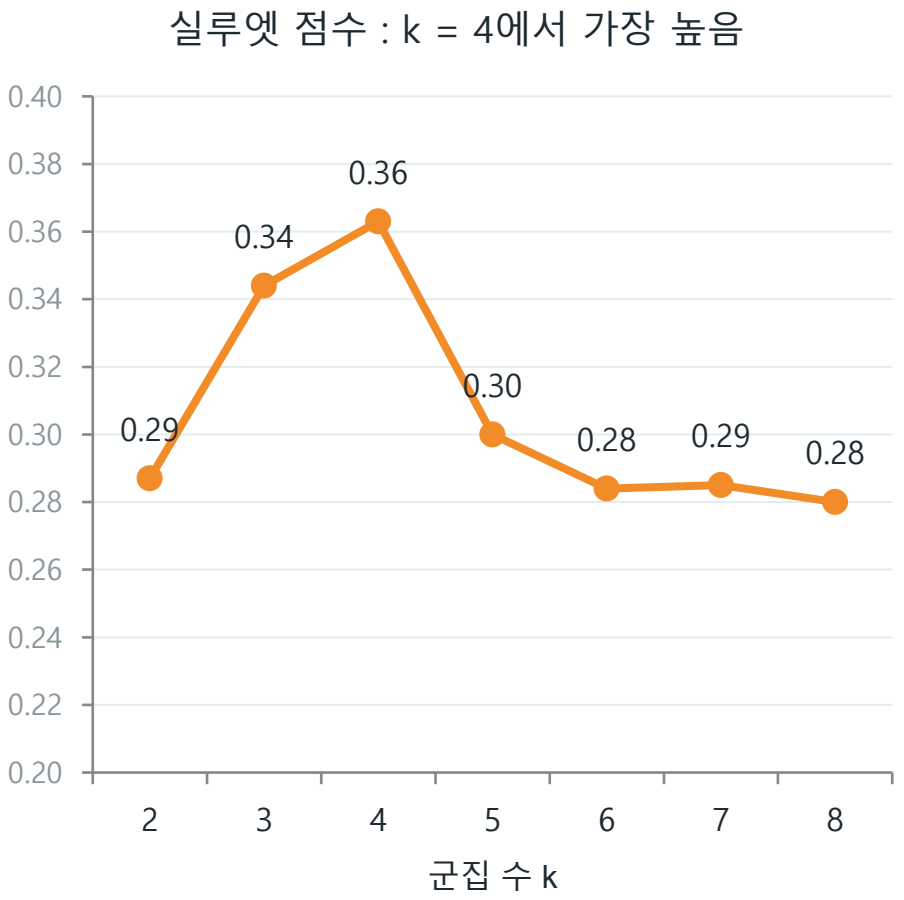
5 **그림 → 저장**

PCA로 확인, 모델 저장

셀 13~15

핵심 **로그 변환이 없으면 군집이 망가진다**

✅ **정상 확인** 셀 5 "판매자 수 : 2,502명" · 셀 9 "가장 높은 k : 4"



⑤ 무엇을 알았나?

PART 8

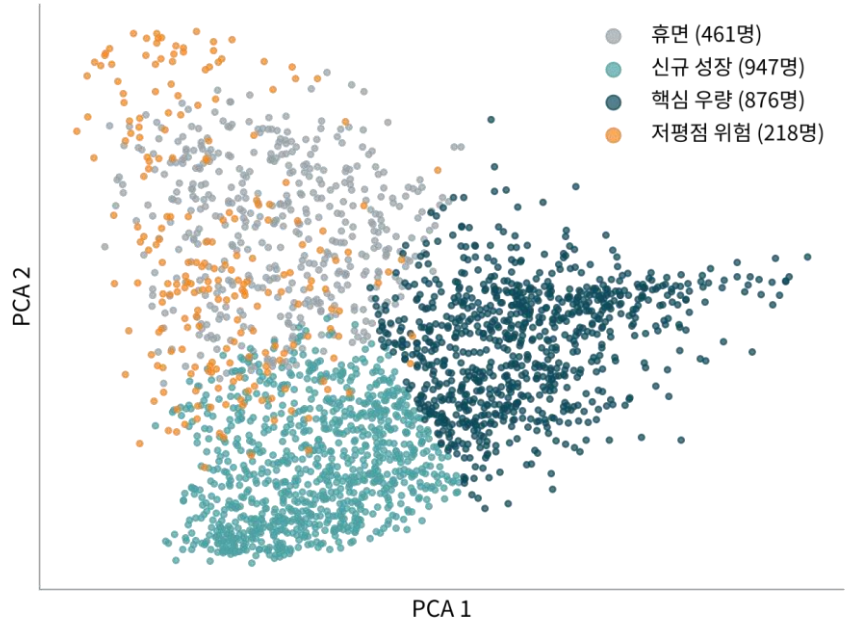
판매자는 4가지 유형으로 나뉜다

핵심 우량 876명 — 주문 38건 · 최근에도 활발

신규 성장 947명 — 시작한 지 약 3개월

휴면 461명 — 약 11개월째 판매 없음

저평점 위험 218명 — 평균 평점 약 1.6점



PCA : 특징 5개를 2개 축으로 줄여서 본 4가지 유형

저평점 위험 : 평균 배송 약 22일 · 출고 지연 33% → 판매자 출고 단계부터 늦음

💾 part8_seller_segment.pkl 약 3KB · PART 9·10에서 사용

① 무엇을 하기 위해?

PART 9

판매를 멈출 판매자를 미리 찾는다

최근까지 팔던 판매자 중 누가 판매를 멈출까?

떠날 판매자를 미리 찾아 연락·지원하면 상품 구색과 매출을 지킬 수 있습니다.

1 왜 고객이 아니라 판매자?

고객은 97%가 한 번만 구매해 거의 전부 '이탈'입니다. 판매자는 매달 반복해서 팔아 '멈췄다'를 정의할 수 있습니다.

2 이탈 = 실습용 정의

3개월 동안 주문이 0건이면 이탈입니다. 실제 탈퇴·폐업과는 다릅니다.

② 어떤 데이터로?

PART 9

과거로 특징을, 미래로 정답을 만든다

기준일 2018-06-01

관찰 구간 → 특징(X)
2017-01 ~ 2018-05

활동 확인
3~5월에 판매 있음

예측 구간 → 정답(y)
2018-06 ~ 08 · 주문 0건이면 이탈

1,567명
3~5월에 판매한 판매자 (전체 3,095명 중)

24.1%
이탈 377명 · 유지 1,190명

1,253 / 314
train / test (이탈 비율 똑같이)

왜 이렇게?

이미 멈춘 판매자는 예측할 의미가 없어 최근 활동한 판매자만 · 원본이 2018-08-29에 끝나 예측 구간은 실제로 약 2.8개월

③ 어떤 알고리즘으로?

PART 9

규칙부터 만들고 머신러닝과 비교한다

1 규칙

- 최근 30일 판매 없으면 이탈
- 기준(30일)은 사람이 정함

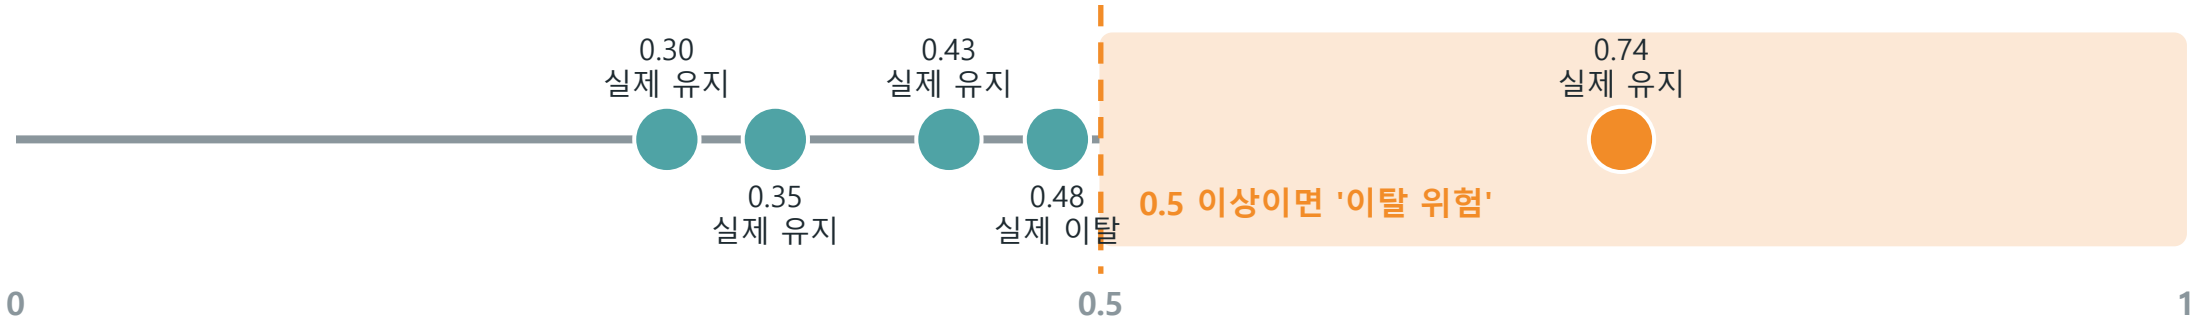
2 로지스틱 회귀

- 특징마다 가중치 → 이탈 확률
- 배포 모델 (약 2KB)

3 랜덤 포레스트

- 트리 100개의 투표
- 비교용

머신러닝은 판매자마다 이탈 확률을 준다 (저장한 모델로 예측한 판매자 5명 · 학습에 쓴 판매자 포함)



④ 어떻게?

PART 9

노트북은 이 순서로 진행된다

1

특징 + 정답

기준일 전 특징, 이후 3개월 정답

셀 3~6

2

test 분리

20% 먼저 떼어 두기

셀 7

3

규칙 만들기

최근 N일을 train에서 고르기

셀 8

4

교차검증 비교

4가지 모델 × 5번

셀 9~11

5

test 평가

혼동행렬 · 계수 · 중요도

셀 12~14

6

유형 해석 → 저장

PART 8 유형별 이탈률

셀 15~18

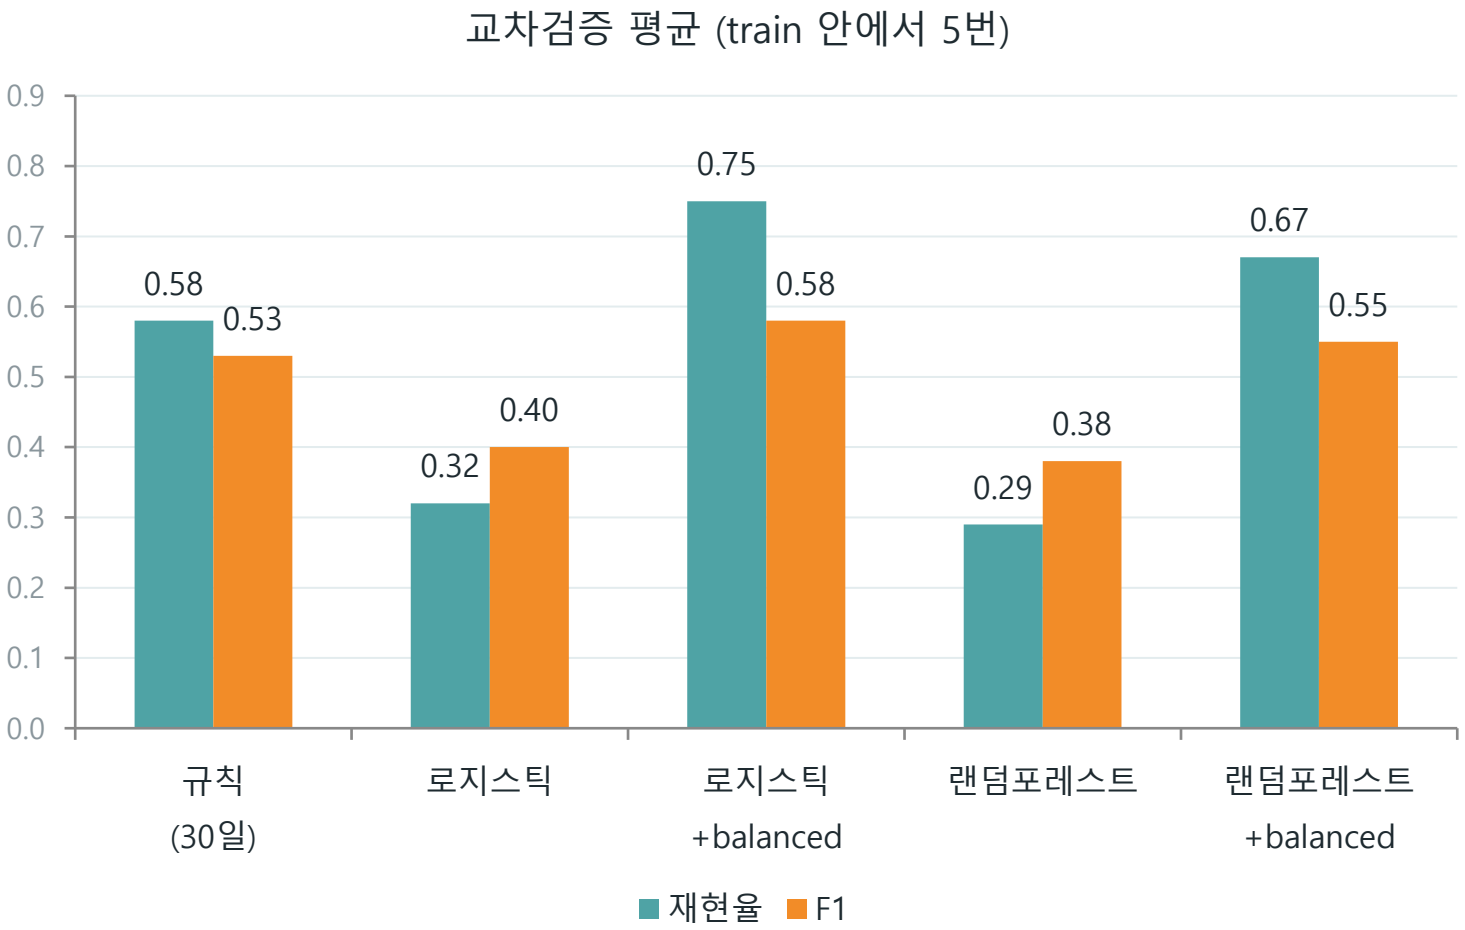
핵심 **test는 마지막에 딱 한 번 · 모델 고르기는 교차검증으로**

✅ **정상 확인** 셀 6 "대상 판매자 1,567명 · 이탈 377명 (24.1%)"

⑤ 무엇을 알았나?

PART 9

머신러닝이 규칙을 조금, 꾸준히 이긴다



0.32 → 0.75

class_weight로 재현율 상승 (로지스틱)

5번 중 5번

로지스틱(balanced)이 규칙보다 F1 높음

유형별 이탈률 : 핵심 우량 17% · 신규 성장 28% · 저평점 위험 66%

part9_seller_churn.pkl 약 2KB

① 무엇을 하기 위해?

PART 10

분석과 모델을 '실행 목록'으로 바꾼다

지금까지 만든 모델로 내일 무엇을 할 수 있을까?

학습은 하지 않습니다. 저장한 모델을 가장 최근 데이터에 적용해 연락할 판매자, 확인할 리뷰 목록을 만듭니다.

1 데이터가 문제를 정한다

고객 1명이 산 상품은 평균 1.07개, 고객 × 상품 표는 0.003%만 채워져 있습니다. 그래서 고객 대신 상품(6)과 판매자(9)로 문제를 바꿨습니다.

2 점수가 아니라 행동

모델의 가치는 정확도가 아니라 '누구에게 무엇을 할지'를 바꾸는 데 있습니다.

② 무엇을 쓰나?

PART 10

저장한 모델을 최신 시점에 적용한다

모델 파일	만든 곳	용도	크기	구분
part6_recommend.pkl	PART 6	유사 상품 추천	약 160KB	배포
part7_1_sentiment_ml.pkl	PART 7-1	리뷰 감성	약 180KB	배포
part7_2_...keras + tokenizer	PART 7-2	리뷰 감성 (딥러닝)	약 3MB	비교용
part8_seller_segment.pkl	PART 8	판매자 유형	약 3KB	배포
part9_seller_churn.pkl	PART 9	이탈 확률	약 2KB	배포

약 340KB

배포 모델 4개 합계

적용 기준일

- 2018-08-23 (8월 22일까지)
- 8월 하순은 수집 종료로 주문이 급감 → 제외
- 최근 3개월(5/23~8/22)에 판매한 판매자 1,817명
- 예측 : 이후 3개월 이탈 확률

③ 어떻게?

PART 10

노트북은 이 순서로 진행된다

1

결과 요약

PART 5~9 한 장 정리

마크다운

2

고객 모델 불가 확인

한 번만 구매 97% · 빈칸 표

셀 3~4

3

모델 점검

파일 · 크기 확인

셀 5

4

판매자 적용

유형 + 이탈 확률 → 우선순위

셀 6~9

5

리뷰 · 추천 적용

불일치 리뷰 · 비슷한 상품

셀 10~11

6

전략 정리

문제 → 근거 → 실행 → KPI

마크다운

핵심 **학습 없이 저장한 모델만 불러와 쓴다 (STEP2 서빙과 같은 방식)**

✅ **정상 확인** 셀 5에서 배포용 4개가 모두 "✅ 있음", 합계 약 340KB

PART 10

이탈 확률 × 판매액으로 줄을 세운다

유형	낮음	보통	높음	매우 높음
핵심 우량	498	149	106	104
신규 성장	244	288	219	173
휴면	0	0	1	4
저평점 위험	0	1	6	24

이탈 위험 단계별 판매자 수 (1,817명)

핵심 우량인데 위험이 높은 210명 = 가장 먼저 연락할 대상

예상 손실 = 확률 × 판매액

확률만 보면 판매액이 작은 판매자에게, 판매액만 보면 떠날 생각 없는 판매자에게 시간을 씁니다. 둘을 곱해 줄을 세웁니다.

637명

확률 0.5 이상 (35%) · class_weight로 놓치지 않는 쪽으로 학습했기 때문 → 인원이 많으면 기준을 올리거나 위에서부터 처리

PART 10

별점만 봐서는 못 찾는 불만이 있다

23건

별점 4~5점인데 글은 강한 불만 (2018-08 리뷰 3,471건 중)

33% vs 23%

모델이 본 부정 비율 vs 실제 1~2점 비율

실제 예시 (별점 4점)

- "AINDA NÃO RECEBI O PRODUTO" → 아직 상품을 못 받았다
- "Comprei preto veio azul ... com defeito" → 검정을 샀는데 파랑이 왔고 불량
- "não obtive retorno até o momento" → 아직 답변을 못 받았다

왜 모델이 더 많이 잡나?

부정을 놓치지 않게(class_weight) 학습했고, 학습 때 뺀 3점 리뷰도 함께 분류했기 때문입니다. 자동 분류는 '사람이 확인할 목록을 줄여 주는 도구'로 씁니다.

추천 적용

실습 상품 중 판매 1위(건강·뷰티, R$87)에 여러 특징이 가까운 같은 카테고리 상품 5개를 붙였습니다.

⑥ 전략 정리

PART 10

문제 → 근거 → 실행 → 측정

문제 (PART 5)	근거 (모델)	실행	측정 (KPI)
재구매 3%, 성장은 신규 유입뿐	**PART 6 유사 상품 추천**	상품 페이지에 '비슷한 상품' → 객단가 ↑	추천 클릭률, 객단가
배송 지연 → 리뷰 급락	**PART 7-1 감성 분류**	부정 리뷰 자동 분류 → CS 우선 대응	응답 시간, 재리뷰 평점
지연·저평점이 일부 판매자에 몰림	**PART 8 판매자 유형**	저평점 위험 → 출고 관리 / 신규 → 온보딩	유형별 출고 지연율
판매자가 떠나면 구색·매출 감소	**PART 9 이탈 확률**	확률 × 판매액 순으로 연락·지원	3개월 뒤 실제 이탈률

한계 : 추천은 고객 반응을 모름(A/B 테스트 필요) · 이탈 정의는 실습용 · 모델은 3개월마다 다시 학습

용어 정리

다시 볼 개념 한 장

KNN	특징 거리가 가장 가까운 k개 찾기 (6)	**로그 변환**	한쪽으로 치우친 값을 고르게 펴기 (6·8·9)
스케일링	단위가 다른 값을 같은 기준으로 (6·8·9)	**TF-IDF**	단어가 그 리뷰를 얼마나 잘 나타내는지 점수 (7-1)
Embedding	단어 번호를 의미 벡터로 (7-2)	**사전학습 모델**	이미 학습된 모델을 가져다 쓰기 (7-3)
K-Means	중심점 k개 기준으로 비슷한 것끼리 묶기 (8)	**실루엣 점수**	군집이 얼마나 잘 나뉘었나 (8)
데이터 누수	모를 정보가 학습에 섞이는 것 (7·8·9)	**class_weight**	적은 쪽을 틀리면 벌점을 크게 (7·9)
재현율 · 정밀도	실제 중 찾아낸 비율 · 찾았다고 한 것 중 맞은 비율 (7·9)	**교차검증**	여러 번 나눠 평가해 평균 보기 (9)

정리

파트별 핵심과 배포할 모델

파트	핵심 메시지	배포 모델	크기
PART 6	같은 카테고리라도 다 비슷하진 않다 → KNN	part6_recommend.pkl	약 160KB
PART 7	딥러닝도 크게 이기지 못한다 → 가벼운 머신러닝	part7_1_sentiment_ml.pkl	약 180KB
PART 8	판매자를 4가지 유형으로 나눈다	part8_seller_segment.pkl	약 3KB
PART 9	규칙보다 머신러닝이 조금, 꾸준히 낫다	part9_seller_churn.pkl	약 2KB
PART 10	확률 × 영향으로 실행 순서를 정한다	(앞의 4개를 불러와 사용)	-

약 340KB

배포 모델 4개 합계 → STEP2에서 서빙

공통 메시지 : 단순한 방법과 먼저 비교하고, 나아질 때 복잡한 방법을 쓴다